

# Econometria | 2023/2024

## Lezione 10: Modelli per probabilità

---

**Giuseppe Ragusa**

<https://gragusa.org>

Roma, marzo 2023



# Sommario

1. Modello lineare di probabilità
2. Regressioni probit e logit
3. Stima e inferenza nei modelli logit e probit
4. Applicazione alla discriminazione razziale nelle concessione dei mutui

# Variabili dipendenti binarie: qual è la differenza?

Variabile dipendente  $(Y)$  continua:

- punteggio nei test medio a livello di tutto il distretto
- tasso di mortalità stradale

Che cosa succede se  $(Y)$  è binaria?

- $(Y=1)$  frequentare università oppure no;  $(X=1)$  voti del liceo, punteggi SAT, variabili demografiche
- $(Y=1)$  la persona fuma oppure no;  $(X=1)$  imposte sulle sigarette, reddito, variabili demografiche
- $(Y=1)$  domanda di mutuo accettata oppure no;  $(X=1)$  ethnicity, reddito, caratteristiche della casa, stato civile

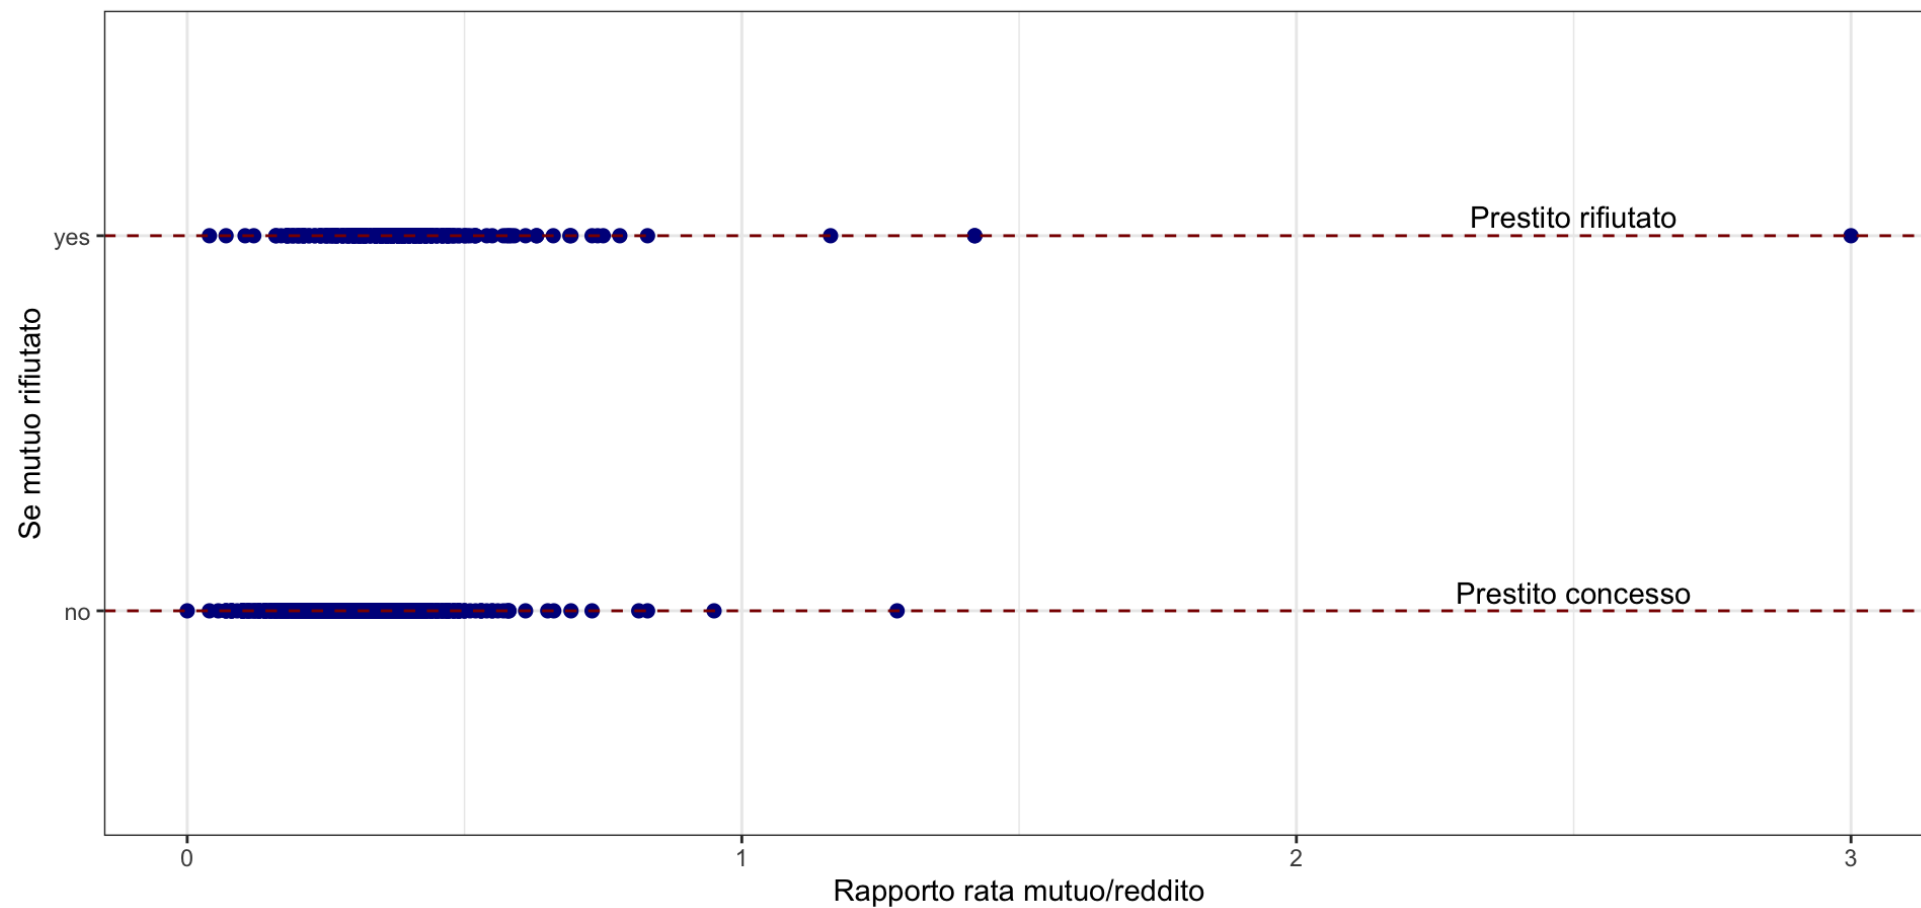
# Esempio: Boston Fed HMDA

- Domande individuali per mutui unifamiliari effettuate nel 1990 nell'area della città di Boston
- 2380 osservazioni, raccolte ai sensi della legge Home Mortgage Disclosure Act (HMDA)

## Variabili

- Variabile dipendente:
  - il mutuo è concesso o negato?
- Variabili indipendenti:
  - reddito, ricchezza, stato occupazionale
  - altro prestito, caratteristiche della proprietà
  - etnia del richiedente

Scatterplot richiesta mutuo



Cosa significa adattare una retta di regressione ad una variabile dipendente che può assumere solo valori zero e uno?

# Modello lineare di probabilità (Paragrafo 11.1)

Consideriamo modello di regressione lineare con un singolo regressore e  $(Y)$  binaria:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

Interpretazione di:

- $\beta_1$
- $\beta_0 + \beta_1 X_i$
- $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_i$

# Il modello lineare di probabilità (continua)

Modello lineare di probabilità:  $Y_i = \beta_0 + \beta_1 X_i + u_i$

$E(Y|X) = 1 \times \Pr(Y=1|X) + 0 \times \Pr(Y=0|X) = \Pr(Y=1|X)$

Sotto l'assunzione  $E(u_i|X_i) = 0$ :

$E(Y_i|X_i) = E(\beta_0 + \beta_1 X_i + u_i|X_i) = \beta_0 + \beta_1 X_i$

$\implies \Pr(Y=1|X) = \beta_0 + \beta_1 X_i$

# Il modello lineare di probabilità (continua)

Il **modello lineare di regressione**

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

è chiamato **modello lineare di probabilità** quando  $(Y)$  è **binaria** perchè

$$\Pr(Y=1|X) = \beta_0 + \beta_1 X$$

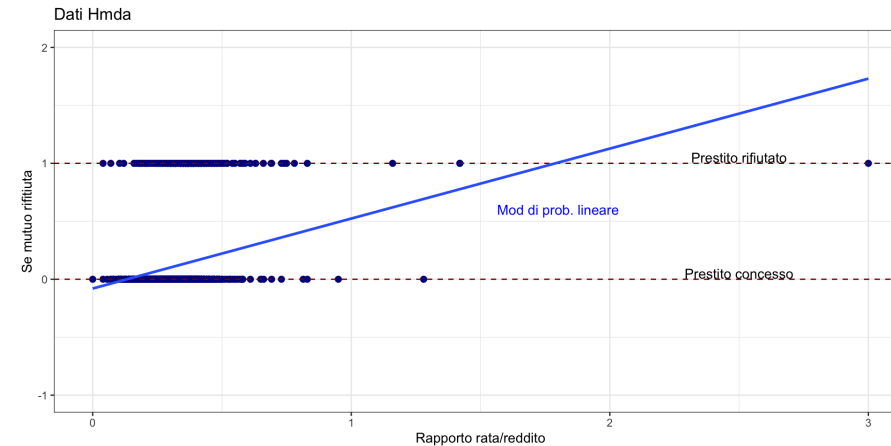
• Implicazioni:

- $E(Y|X=x) = \Pr(Y=1|X=x)$ : prob. che  $(Y=1)$  data  $(X)$
- $(\beta_1)$  variazione della probabilità che  $(Y=1)$  per una variazione unitaria in  $(X)$ , o più generalmente  $\beta_1 = \frac{\Pr(Y=1|X=x+\Delta x) - \Pr(Y=1|X=x)}{\Delta x}$
- $(\hat{Y})$  **probabilità attesa stimata** che  $(Y_i = 1)$ , data  $(X)$



# Esempio: modello lineare di probabilità, dati HMDA

```
1 Hmda <- Hmda %>%
2   mutate(denied = ifelse(deny=="yes", 1, 0))
3
4 ggplot(Hmda, aes(x = dir, y = denied)) +
5   geom_point(size=2, col = 'darkblue') +
6   theme_bw() +
7   labs(x = "Rapporto rata/reddito",
8        y = "Se mutuo rifiutata",
9        title = "Dati Hmda") +
10  ylim(c(-1,2)) +
11  geom_hline(yintercept=1, lty = 2,
12            col = "darkred") +
13  geom_hline(yintercept=0, lty = 2,
14            col = "darkred") +
15  annotate("text", x = 2.5, y = 1.05,
16          label = "Prestito rifiutato") +
17  annotate("text", x = 2.5, y = 0.05,
18          label = "Prestito concesso") +
19  geom_smooth(method='lm',
20            formula= y~x, se=FALSE) +
21  annotate("text", x = 1.8, y = 0.6,
22          label = "Mod di prob. lineare",
23          col="blue")
```



# Modello lineare di probabilità: Hmda

```
1 lpm1 <- feols(denied ~ dir, data=Hmda, vcov = "hetero")
2 lpm1
```

OLS estimation, Dep. Var.: denied

Observations: 2,381

Standard-errors: Heteroskedasticity-robust

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-0.080	0.0320	-2.50	1.2436e-02 *
dir	0.604	0.0985	6.13	1.0353e-09 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

RMSE: 0.318093 Adj. R2: 0.039332

- Probabilità stimata quando  $(dir=0.3)$  (rata pari al 30% del reddito)?

$\Pr(deny=1|dir=0.3) = -0.08 + 0.604 \times 0.3 = 0.101 = 10.1\%$

- Probabilità stimata quando  $(dir=0.4)$  (rata pari al 40% del reddito)?

$\Pr(deny=1|dir=0.4) = -0.08 + 0.604 \times 0.4 = 0.162 = 16.2\%$

- L'effetto di un aumento del **rapporto mutuo/reddito**,  $(dir)$ , di 0.1 è un aumento della probabilità che il mutuo venga rigettato di 0.061 (o 6.1 **punti percentuali**)

# Modello lineare di probabilità: Hmda, ctd.

```
1 lpm2 <- feols(denied ~ dir+black, data=Hmda, vcov = "hetero")
2 lpm2
```

OLS estimation, Dep. Var.: denied

Observations: 2,381

Standard-errors: Heteroskedasticity-robust

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	-0.0906	0.0286	-3.17	1.5626e-03	**
dir	0.5592	0.0887	6.31	3.3839e-10	***
blackyes	0.1775	0.0249	7.11	1.4801e-12	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

RMSE: 0.312025 Adj. R2: 0.075244

- Probabilità stimata quando  $(dir=0.3)$  (rata pari al 30% del reddito) e  $(black=1)$

$[Pr(denied=1|dir=0.3, black=1) = -0.091 + 0.559 \times 0.3 + 0.177 \times 1 = 0.254]$

- Probabilità stimata quando  $(dir=0.4)$  (rata pari al 40% del reddito) e  $(black=1)$

$[Pr(denied=1|dir=0.3, black=1) = -0.091 + 0.559 \times 0.3 + 0.177 \times 0 = 0.077]$

- differenza  $(0.254 - 0.077 = 0.177 = 17.7)$  punti percentuali

# Modello lineare di probabilità: riepilogo

Nel modello lineare di probabilità,  $\Pr(Y=1|X)$  è lineare in  $X$

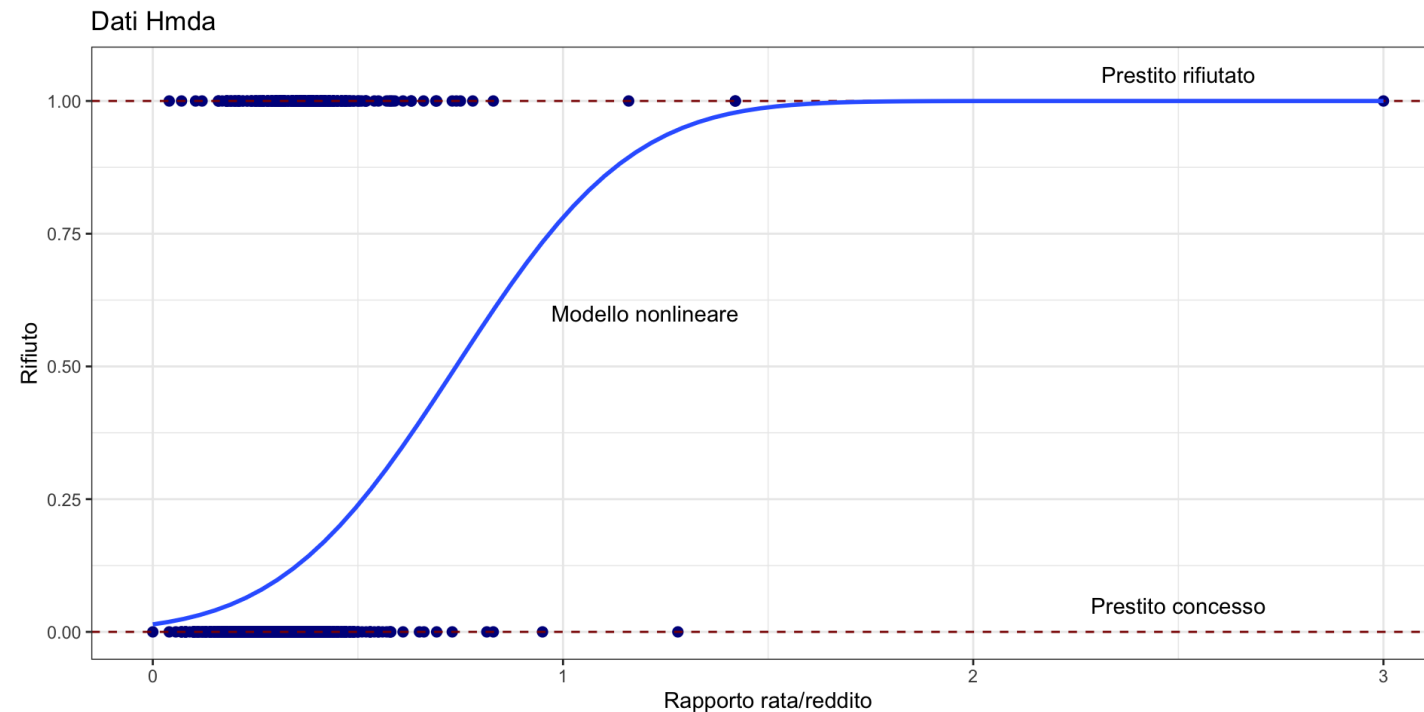
- **Vantaggi:**
  - semplice da stimare e interpretare
  - l'inferenza è la stessa della regressione multipla (occorrono errori standard robusti all'eteroschedasticità)
- **Svantaggi:**
  - Le probabilità previste possono essere  $<0$  o  $>1$ !
  - Implicazioni del modello lineare per la probabilità che  $Y=1$  poco sensate
- Alternativa: modello **non lineare** di probabilità: **probit** e **logit**

# Regressioni probit e logit (Paragrafo 11.2)

Desiderata:

- a.  $\Pr(Y=1|X)$  crescente in  $X$  per  $(\beta_1 > 0)$  e
- b.  $0 \leq \Pr(Y=1|X) \leq 1$  per tutte le  $X$

Ciò richiede l'utilizzo di una forma funzionale **non lineare** per la probabilità



# Regressione probit

- Il modello **probit** è:

$\Pr(Y=1|X) = \Phi(\beta_0 + \beta_1 X)$  dove  $\Phi(\cdot)$  è la funzione di ripartizione normale

## Esempio:

Se  $\beta_0 = -2$ ,  $\beta_1 = 3$ , and  $X = 0.4$ , allora:

$$\Pr(Y=1|X=0.4) = \Phi(-2 + 3 \times 0.4) = \Phi(-0.8) = 0.212$$

# Regressione probit (continua)

- La funzione di ripartizione normale ha una forma a S e, quindi,
  - a.  $\Pr(Y=1|X)$  crescente in  $X$  per  $\beta_1 > 0$  e
  - b.  $0 \leq \Pr(Y=1|X) \leq 1$  per tutte le  $X$
- Legame con modelli economici di scelta ottima
- Interpretazione di  $\beta_1$   $\left[ \frac{d\Pr(Y=1|X)}{dX} = \phi(\beta_0 + \beta_1 X) \beta_1 \right]$   
 $\beta_1$  determina il segno dell'effetto di una variazione di  $X$  su  $\Pr(Y=1|X)$

# Esempio in R: dati HMDA

```
1 probit1 <- feglm(denied ~ dir, family = binomial("probit"), data=Hmda)
2 probit1
```

```
GLM estimation, family = binomial, Dep. Var.: denied
Observations: 2,381
Standard-errors: IID
      Estimate Std. Error z value   Pr(>|z|)
(Intercept)  -2.19      0.138  -15.93 < 2.2e-16 ***
dir           2.97      0.386   7.69 1.4442e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Log-Likelihood: -831.9   Adj. Pseudo R2: 0.045059
BIC: 1,679.4          Squared Cor.: 0.051522
```

$\Pr(\text{deny}=1|\text{dir}) = \Phi(-2.19 + 2.97 \times \text{dir})$  - Coefficiente positivo: maggiore  $\text{dir}$  maggiore è la probabilità che il mutuo sia rifiutato



# Esempio in R: Hmda, ctd.

```
GLM estimation, family = binomial, Dep. Var.: denied
Observations: 2,381
Standard-errors: IID
      Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.19      0.138  -15.93 < 2.2e-16 ***
dir           2.97      0.386   7.69 1.4442e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Log-Likelihood: -831.9   Adj. Pseudo R2: 0.045059
               BIC: 1,679.4   Squared Cor.: 0.051522
```

- Probabilità prevista quando  $(dir=0.3)$ :

$$\Pr(deny=1|dir=0.3) = \Phi(-2.19 + 2.97 \times 0.3) = \Phi(-1.30) = 0.097$$

- Probabilità stimate quando  $(dir=0.4)$ :  $\Pr(deny=1|dir=0.4) = \Phi(-2.19 + 2.97 \times 0.4) = \Phi(-1.00) = 0.159$

La probabilità prevista di rifiuto passa da 0.097 a 0.159

# Regressione probit con regressori multipli

$$\Pr(Y=1|X_1, X_2) = \Phi(\beta_0 + \beta_1 X_1 + \beta_2 X_2)$$

- $\Phi(\cdot)$  è la funzione di ripartizione normale
- Interpretazione coefficienti:  $\frac{\partial \Pr(Y=1|X_1, X_2)}{\partial X_1} = \frac{d\Phi(\beta_0 + \beta_1 X_1 + \beta_2 X_2)}{dX_1} = \phi(\beta_0 + \beta_1 X_1 + \beta_2 X_2) \beta_1$   $\phi(\beta_1)$  cattura effetto *ceteris paribus* sul segno

# Esempio in R: Dati HMDA

```
GLM estimation, family = binomial, Dep. Var.: denied
Observations: 2,381
Standard-errors: IID
      Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.259      0.1368  -16.5 < 2.2e-16 ***
dir           2.742      0.3807   7.2 5.8682e-13 ***
blackyes      0.708      0.0834   8.5 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Log-Likelihood: -797.2    Adj. Pseudo R2: 0.083677
BIC: 1,617.8    Squared Cor.: 0.087201
```

- Il coefficiente di `black` è statisticamente significativo?

$$\Pr(\text{deny}=1|\text{dir}=0.3, \text{black}=1) = \Phi(-2.26 + 2.74 \times 0.3 + 0.71 \times 1) = \Phi(-0.728) = 0.233$$
$$\Pr(\text{deny}=1|\text{dir}=0.3, \text{black}=0) = \Phi(-2.26 + 2.74 \times 0.3 + 0.71 \times 0) = \Phi(-1.438) = 0.075$$

- Differenza nelle probabilità di rifiuto = 0.158 (15.8 punti percentuali)
- Ancora molto spazio per distorsione da variabili omesse!

# Esempio in R (continua): probabilità probit previste

```
1 ## Differenza probability black/nonblack per dir=0.3
2 predict(probit2, newdata=data.frame(dir=0.3, black="yes"), type = "response") -
3   predict(probit2, newdata=data.frame(dir=0.3, black="no"), type = "response")
```

```
[1] 0.158
```

# Effetti marginali

Valori diversi di  $\text{dir}$  danno valori diversi della variazione di  $\Pr(Y=1|X)$ ...

Two approaches:

- Calcolare l'effetto per un valore rappresentativo di  $\text{dir}$ , e.g.,  $\bar{\text{dir}}$

```
1 ## Differenza probability black/nonblack per dir=media(dir)
2 dirbar <- mean(Hmda$dir)
3 predict(probit2, newdata=data.frame(dir=dirbar, black="yes"), type = "response") -
4   predict(probit2, newdata=data.frame(dir=dirbar, black="no"), type = "response")
```

```
[1] 0.172
```

- Calcolare gli effetti per i valori  $\text{dir}_i$ ,  $(i=1, \dots, n)$  e calcolare la media

```
1 ## Differenza probability black/nonblack per dir=dir_i
2 effetti <- predict(probit2, newdata=data.frame(dir=Hmda$dir, black="yes"), type = "response") -
3   predict(probit2, newdata=data.frame(dir=Hmda$dir, black="no"), type = "response")
4 mean(effetti)
```

```
[1] 0.17
```

# Effetti marginali

```
1 library(marginaleffects)
2 ## Valuta effetti alla media (avg) per e calcola standard error
3 avg_slopes(probit2, newdata = "mean")
```

Term	Contrast	Estimate	Std. Error	z	Pr(> z )	S	2.5 %	97.5 %
black	yes - no	0.172	0.0247	6.95	<0.001	38.0	0.123	0.220
dir	dY/dX	0.439	0.0625	7.02	<0.001	38.7	0.316	0.561

Columns: term, contrast, estimate, std.error, statistic, p.value, s.value, conf.low, conf.high  
Type: response

```
1 ## Valuta la media degli effetti (AME) e calcola standard error
2 avg_slopes(probit2)
```

Term	Contrast	Estimate	Std. Error	z	Pr(> z )	S	2.5 %	97.5 %
black	yes - no	0.170	0.0243	6.99	<0.001	38.5	0.122	0.217
dir	dY/dX	0.501	0.0690	7.26	<0.001	41.3	0.366	0.637

Columns: term, contrast, estimate, std.error, statistic, p.value, s.value, conf.low, conf.high  
Type: response

# Regressione logit

- Modella la probabilità di  $(Y=1)$ , data  $(X)$ , come funzione di ripartizione **logistica** standard, valutata in  $(z=\beta_0+\beta_1 X)$ :

$\Pr(Y=1|X)=F(\beta_0+\beta_1 X)$  dove  $(F)$  è la funzione di ripartizione **logistica**:

$$F(\beta_0+\beta_1 X)=\frac{1}{1+e^{-(\beta_0+\beta_1 X)}}$$

Poiché le regressioni logit e probit utilizzano **funzioni di probabilità diverse**, i **coefficienti  $(\beta)$  sono diversi** nelle regressioni logit e probit.

# Regressione logit (continua)

$$\Pr(Y=1|X) = F(\beta_0 + \beta_1 X)$$

dove:

$$F(\beta_0 + \beta_1 X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

**Esempio:**  $\beta_0 = 3, \beta_1 = 2, X = 0.4$

- quindi  $\beta_0 + \beta_1 X = 3 + 2 \times 0.4 = 2.2$
- perciò  $\Pr(Y=1|X=0.4) = \frac{1}{1 + e^{-2.2}} = 0.0998$

A che scopo utilizzare logit se disponiamo di probit?

- Il motivo principale è storico: dal punto di vista del calcolo, logit è più veloce
- **logit** e **probit** danno risultati spesso simili



# Esempio in R: Dati HMDA

```
1 logit2 <- feglm(denied ~ dir+black, family = binomial("logit"), data=Hmda)
2 logit2
```

GLM estimation, family = binomial, Dep. Var.: denied

Observations: 2,381

Standard-errors: IID

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	-4.13	0.269	-15.37	< 2.2e-16 ***
dir	5.37	0.729	7.37	1.6925e-13 ***
blackyes	1.27	0.146	8.71	< 2.2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Log-Likelihood: -795.8 Adj. Pseudo R2: 0.085331

BIC: 1,614.9 Squared Cor.: 0.088796

```
1 predict(logit2, newdata= data.frame(dir=0.3, black="no"), type = "response")
```


```
[1] 0.0748
```

```
1 predict(probit2, newdata= data.frame(dir=0.3, black="no"), type = "response")
```

```
[1] 0.0754
```

# Confronto grafico probit e logit

```
1 ggplot(Hmda, aes(x = dir, y = denied)) +  
2   geom_point(size=2, col = 'darkblue') +  
3   theme_bw() +  
4   labs(x = "Rapporto rata/reddito") +  
5   labs(y = "Rifiuto", title = "Dati Hmda") +  
6   geom_hline(yintercept=0, lty = 2,  
7             col = "darkred") +  
8   geom_hline(yintercept=1, lty = 2,  
9             col = "darkred") +  
10  annotate("text", x = 2.5, y = 1.05,  
11         label = "Prestito rifiutato") +  
12  annotate("text", x = 2.5, y = 0.05,  
13         label = "Prestito concesso") +  
14  stat_smooth(method="glm", se=FALSE,  
15             col = "maroon",  
16             method.args = list(family=  
17                               binomial(link = "probit"))) +  
18  stat_smooth(method="glm", se=FALSE,  
19             col = "darkblue",  
20             method.args = list(family=  
21                               binomial(link = "logit"))) +  
22  annotate("text", x = .6, y = 0.7,  
23         color = "darkblue",  
24         label = "logit") +  
25  annotate("text", x = 0.84, y = 0.3,  
26         color = "maroon",  
27         label = "probit")
```



# Stima e inferenza nei modelli logit e probit (Paragrafo 11.3)

Ci concentriamo sul modello probit:

$$\Pr(Y=1|X) = \Phi(\beta_0 + \beta_1 X)$$

- Stima e inferenza
  - Come possiamo stimare  $\beta_0$  e  $\beta_1$ ?
  - Qual è la distribuzione campionaria degli stimatori?
  - Perché possiamo utilizzare i metodi usuali di inferenza?
- Anzitutto motiviamo tramite i minimi quadrati non lineari
- Quindi discutiamo della stima di massima verosimiglianza (ciò che effettivamente è fatto nella pratica)

# Stima probit mediante i minimi quadrati non lineari

Ricordiamo OLS:  $\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \left[ Y_i - (\hat{\beta}_0 + \hat{\beta}_1) \right]^2$

- Il risultato sono gli stimatori OLS  $(\hat{\beta}_0, \hat{\beta}_1)$

I minimi quadrati non lineari estendono l'idea di OLS ai modelli nei quali i parametri entrano in modo non lineare:

$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \left[ Y_i - \Phi(\hat{\beta}_0 + \hat{\beta}_1) \right]^2$

- Come risolvere questo problema di minimizzazione?
  - Il calcolo non offre una soluzione esplicita.
  - Risolto numericamente mediante il computer (algoritmi di minimizzazione speciali)
  - In pratica, i minimi quadrati non lineari non sono utilizzati. Uno stimatore più efficiente (varianza più piccola) è

# Stimatore di massima verosimiglianza

La **funzione di verosimiglianza** è la distribuzione di  $(Y_1, \dots, Y_n)$  condizionata a  $(X_1, \dots, X_n)$  trattata come funzione dei parametri ignoti  $(\beta_0, \beta_1)$ .

- Lo stimatore di massima verosimiglianza (MLE) è il valore di  $(\beta_0, \beta_1)$  che massimizza la funzione di verosimiglianza.
- MLE sceglie i parametri per massimizzare la probabilità di estrarre i dati effettivamente osservati.
- MLE è il valore di  $(\beta_0, \beta_1)$ , cioè i parametri che “più verosimilmente” hanno generato i dati.
- In grandi campioni, MLE è:
  - consistente
  - normalmente distribuito
  - efficiente (ha la più piccola varianza di tutti gli stimatori)

# Caso speciale: MLE probit senza alcuna $(X)$

Distribuzione di Bernoulli:

$Y = \begin{cases} 1 & \text{con probabilità } p \\ 0 & \text{con probabilità } (1-p) \end{cases}$

Dati:  $(Y_1, \dots, Y_n)$  i.i.d.

La derivazione della verosimiglianza inizia con la distribuzione di  $(Y_1)$ :

$$\Pr(Y_1=y_1) = p^{y_1} (1-p)^{1-y_1}$$

Distribuzione congiunta di  $((Y_1, Y_2))$ : poiché  $(Y_1)$  e  $(Y_2)$  sono indipendenti:

$$\begin{aligned} \Pr(Y_1=y_1, Y_2=y_2) &= \Pr(Y_1=y_1) \times \Pr(Y_2=y_2) = [p^{y_1} (1-p)^{1-y_1}] \times [p^{y_2} (1-p)^{1-y_2}] \\ &= p^{(y_1+y_2)} (1-p)^{2-(y_1+y_2)} \end{aligned}$$

Distribuzione congiunta di  $((Y_1, \dots, Y_n))$ : poiché  $(Y_1, \dots, Y_n)$  sono indipendenti:

$$\begin{aligned} \Pr(Y_1=y_1, Y_2=y_2, \dots, Y_n=y_n) &= \Pr(Y_1=y_1) \times \Pr(Y_2=y_2) \\ &\times \dots \times \Pr(Y_n=y_n) = [p^{y_1} (1-p)^{1-y_1}] \times [p^{y_2} (1-p)^{1-y_2}] \\ &\times \dots \times [p^{y_n} (1-p)^{1-y_n}] = p^{\sum_{i=1}^n y_i} (1-p)^{\left(n - \sum_{i=1}^n y_i\right)} \end{aligned}$$

La verosimiglianza è la distribuzione congiunta, trattata come funzione dei parametri non noti, che qui è  $\ell(p)$ :

$$\ell(p; Y_1, \dots, Y_n) = p^{\sum_{i=1}^n y_i} (1-p)^{\left(n - \sum_{i=1}^n y_i\right)}$$

MLE massimizza la verosimiglianza. È più facile lavorare con il **logaritmo** della verosimiglianza,  $\ln \ell(p; Y_1, \dots, Y_n)$ :

$$\ln \ell(p; Y_1, \dots, Y_n) = \left(\sum_{i=1}^n y_i\right) \ln(p) + \left(n - \sum_{i=1}^n y_i\right) \ln(1-p)$$

Massimizzare la verosimiglianza impostando la derivata =0:

$$\frac{d \ln \ell(p; Y_1, \dots, Y_n)}{dp} = \left(\sum_{i=1}^n y_i\right) \frac{1}{p} + \left(n - \sum_{i=1}^n y_i\right) \left(\frac{-1}{1-p}\right) = 0$$

Risolvendo per  $p$  si ottiene lo stimatore di massima verosimiglianza.



Ovvero,  $\hat{p}^{\text{MLE}}$  soddisfa:

$$\left[ \left( \sum_{i=1}^n y_i \right) \frac{1}{\hat{p}^{\text{MLE}}} + \left( n - \sum_{i=1}^n y_i \right) \left( \frac{-1}{1 - \hat{p}^{\text{MLE}}} \right) = 0 \right]$$
 oppure:

$$\left[ \left( \sum_{i=1}^n y_i \right) \frac{1}{\hat{p}^{\text{MLE}}} = \left( n - \sum_{i=1}^n y_i \right) \left( \frac{1}{1 - \hat{p}^{\text{MLE}}} \right) \right]$$
 oppure:

$$\left[ \frac{\bar{Y}}{1 - \bar{Y}} = \frac{\hat{p}^{\text{MLE}}}{1 - \hat{p}^{\text{MLE}}} \right]$$
 quindi:

$$\left[ \hat{p}^{\text{MLE}} = \bar{Y} = \text{frazione di } 1 \right]$$

# MLE nel caso “No-X”, ctd,

$$\hat{p}^{\text{MLE}} = \bar{Y} = \text{frazione di 1}$$

- Per  $(Y_i)$  i.i.d. di Bernoulli, MLE è lo stimatore “naturale” di  $(p)$ , la frazione di 1, che è  $(\bar{Y})$
- Conosciamo già i fondamenti dell’inferenza:
  - Per  $(n)$  grande, la distribuzione campionaria di  $(\hat{p}^{\text{MLE}} = \bar{Y})$  è normale
  - Perciò l’inferenza è “come di consueto”: verifica di ipotesi tramite statistica  $(t)$ , intervallo di confidenza come  $(\pm 1.96SE)$

# MLE nel caso “No-X” (distribuzione di Bernoulli), continua:

- La teoria della stima di massima verosimiglianza dice che è lo stimatore più efficiente di  $(p)$  - di tutti i possibili stimatori! - almeno per  $(n)$  grande (molto più forte del teorema di Gauss-Markov).
- Per questo motivo MLE è il principale stimatore utilizzato per i modelli nei quali i parametri (coefficienti) entrano in modo non lineare.

Siamo ora pronti a passare a MLE dei coefficienti probit, nel quale la probabilità è condizionata a  $(X)$ .

# La verosimiglianza probit con una $(X)$

La derivazione inizia con la distribuzione di  $(Y_1)$ , data  $(X_1)$  è:

$$\begin{array}{l} \Pr(Y_1=1|X_1)=\Phi(\beta_0+\beta_1 X_1) \\ \Pr(Y_1=0|X_1)=1-\Phi(\beta_0+\beta_1 X_1) \end{array}$$

quindi:

$$\Pr(Y_1=y_1|X_1)=\Phi(\beta_0+\beta_1 X_1)^{y_1} [1-\Phi(\beta_0+\beta_1 X_1)]^{1-y_1}$$

La funzione di verosimiglianza probit è la distribuzione congiunta di  $(Y_1, \dots, Y_n)$  dati  $(X_1, \dots, X_n)$ , come funzione di  $(\beta_0, \beta_1)$

$$\begin{array}{l} f(\beta_0, \beta_1; Y_1, \dots, Y_n | X_1, \dots, X_n) = \Phi(\beta_0+\beta_1 X_1)^{y_1} [1-\Phi(\beta_0+\beta_1 X_1)]^{1-y_1} \times \\ \dots \times \Phi(\beta_0+\beta_1 X_n)^{y_n} [1-\Phi(\beta_0+\beta_1 X_n)]^{1-y_n} \end{array}$$

# La funzione di verosimiglianza probit

$$\begin{aligned} f(\beta_0, \beta_1; Y_1, \dots, Y_n | X_1, \dots, X_n) = & \Phi(\beta_0 + \beta_1 X_1)^{y_1} [1 - \Phi(\beta_0 + \beta_1 X_1)]^{1-y_1} \times \\ & \dots \times \Phi(\beta_0 + \beta_1 X_n)^{y_n} [1 - \Phi(\beta_0 + \beta_1 X_n)]^{1-y_n} \end{aligned}$$

- $(\hat{\beta}_0^{MLE}, \hat{\beta}_1^{MLE})$  massimizzano questa funzione di verosimiglianza
- Ma non possiamo risolvere esplicitamente per il massimo! Così MLE deve essere massimizzato mediante metodi numerici
- Come nel caso di nessuna  $(X)$ , in grandi campioni:
  - $(\hat{\beta}_0^{MLE}, \hat{\beta}_1^{MLE})$  sono consistenti e normalmente distribuiti e asintoticamente efficienti
- Gli errori standard di  $(\hat{\beta}_0^{MLE}, \hat{\beta}_1^{MLE})$  vengono calcolati automaticamente
- La verifica degli intervalli di confidenza procede nel modo consueto
- Tutto ciò si estende a  $(X)$  multiple, per i dettagli si veda l'Appendice 11.2

# La verosimiglianza logit con una $(X)$

- L'unica differenza tra probit e logit è a forma condizionale utilizzata per la probabilità:  $\Phi$  è sostituita dalla funzione di ripartizione logistica
- Altrimenti, la verosimiglianza è simile; per i dettagli si veda l'Appendice 11.2
- Come nel caso probit:
  - $(\hat{\beta}_0^{MLE}, \hat{\beta}_1^{MLE})$  sono consistenti
  - $(\hat{\beta}_0^{MLE}, \hat{\beta}_1^{MLE})$  sono normalmente distribuiti
  - I loro errori standard possono essere calcolati
  - La verifica degli intervalli di confidenza procede nel modo consueto

# Conclusione

- Se  $(Y_i)$  è binaria, allora  $(E(Y|X)=Pr(Y=1|X))$
- Tre modelli:
  - **modelli lineare di probabilità** (regressione lineare multipla)
  - **probit** (funzione di ripartizione normale standard)
  - **logit** (funzione di ripartizione logistica standard)
- LPM, probit, logit tutti producono probabilità predette
- L'effetto di  $(\Delta X)$  è la variazione nella probabilità condizionata che  $(Y=1)$ . Per logit e probit, ciò dipende dalla  $(X)$  **iniziale**
- Probit e logit vengono stimati tramite la massima verosimiglianza
  - I coefficienti hanno distribuzione normale per  $(n)$  grande
  - La verifica di ipotesi e gli intervalli di confidenza per  $n$  grande sono come di consueto